

Dataset — Conceitos e Aplicações na Indústria

1. O que é um Dataset

Um **dataset** é um conjunto organizado de dados, estruturado de forma que possa ser usado para análise, visualização, tomada de decisão ou treinamento de modelos de Inteligência Artificial. Ele funciona como uma tabela, coleção de arquivos ou banco de dados contendo informações relacionadas a um problema específico.

Um dataset pode conter:

- **Linhas:** cada linha representa um registro, amostra ou evento real.
- **Colunas:** cada coluna representa uma característica, variável ou atributo.
- **Metadados:** informações sobre o próprio dataset, como data de criação, unidade de medida, descrição das variáveis, origem dos dados.

Datasets podem ser simples, como uma planilha com dados de vendas, ou extremamente complexos, como coleções de imagens, áudios, medições de sensores industriais ou séries temporais de grandes máquinas.

Datasets podem estar armazenados em vários formatos:

- CSV
- Excel
- JSON
- SQL
- Parquet
- Imagens ou sinais brutos

O papel principal de um dataset é representar a realidade de forma organizada, permitindo que análises e modelos matemáticos consigam extrair padrões.

2. Estrutura Geral de um Dataset

Normalmente um dataset contém:

1. Identificação

Ex.: ID da peça, ID do sensor, código do produto.

2. **Variáveis descritivas (atributos)**

Ex.: temperatura, vibração, pressão, velocidade, corrente elétrica.

3. **Variáveis alvo (quando há previsão)**

Ex.: “falhou = 1”, “funcionando = 0”, “qualidade = aprovado/reprovado”.

4. **Carimbo de tempo (timestamp)**

Ex.: hora e data da coleta de sensor.

5. **Contexto da operação**

Ex.: turno, operador, lote, tipo de matéria-prima.

3. Dataset na Indústria: Por que é tão Importante

A transformação digital e a Indústria 4.0 tornaram datasets essenciais dentro de plantas industriais. Máquinas modernas possuem sensores que registram milhares de dados por minuto.

Com essa base de dados, é possível:

- Detectar falhas antes que aconteçam
- Prever manutenção de motores, bombas e turbinas
- Melhorar a eficiência energética
- Reduzir desperdícios na linha de produção
- Classificar qualidade de produtos
- Analisar produtividade de turnos
- Automatizar tomadas de decisão

Quanto mais rico e organizado o dataset, melhores e mais confiáveis serão os modelos analíticos e preditivos.

4. Exemplos de Datasets Industriais

4.1 Dataset de Sensores de Vibração (Manutenção Preditiva)

Um dataset típico de manutenção preditiva inclui:

timestamp	vibração_x	vibração_y	temperatura	rotação	falha
2024-10-12 12:00	0.02	0.04	61	1800	0
2024-10-12 12:01	0.15	0.14	78	1800	1

Aplicação:

- Prever quando o equipamento começará a falhar
 - Treinar modelo de IA para detectar anomalias
-

4.2 Dataset de Qualidade de Produto (Inspeção Visual)

Pode conter:

lote	densidade	cor	espessura	aprovado
1001	1.02	32	4.1	sim
1002	0.98	27	3.9	não

Aplicação:

- Criar algoritmo de classificação que indique se o produto será aprovado antes mesmo do teste final.
-

4.3 Dataset de Consumo Energético

hora	máquina	consumo_kw	produção_unidades
08h	prensa	34.2	120
09h	prensa	40.1	118

Aplicação:

- Identificar desperdício
 - Prever picos de energia
 - Otimizar horários de operação
-

5. Como Carregar e Explorar um Dataset em Python

Exemplo com Pandas (arquivo CSV):

```
1 import pandas as pd
2
3 df = pd.read_csv("sensores.csv")
4
5 print(df.head())
6 print(df.describe())
7 print(df.info())
```

6. Limpeza e Preparação dos Dados

Datasets reais quase nunca vêm perfeitos. Etapas comuns:

- Remoção de valores nulos
- Conversão de tipos (string → número)
- Normalização de escalas (sensores com unidades diferentes)
- Remoção de outliers (valores impossíveis)

Exemplo:

```
1 df = df.dropna()
2 df["temperatura"] = df["temperatura"].astype(float)
```

7. Aplicando IA em um Dataset Industrial

Exemplo: Prever falha de máquina

Separando variáveis:

```
1 X = df[["vibração_x", "vibração_y", "temperatura", "rotação"]]
2 y = df["falha"]
```

Treinando um modelo simples:

```
1 from sklearn.ensemble import RandomForestClassifier
2
3 modelo = RandomForestClassifier()
4 modelo.fit(X, y)
5
6 previsoes = modelo.predict(X)
```

Avaliação:

```
1 from sklearn.metrics import classification_report
2 print(classification_report(y, previsoes))
```

8. Visualizando Dados Industriais

Visualizações ajudam a entender o dataset e comunicar resultados.

Exemplo com Matplotlib:

```
1 import matplotlib.pyplot as plt
```

```
2
3 plt.plot(df["timestamp"], df["temperatura"])
4 plt.xlabel("Tempo")
5 plt.ylabel("Temperatura")
6 plt.title("Temperatura do Motor ao Longo do Dia")
7 plt.show()
```

9. Conclusão

Datasets são a base de qualquer projeto de análise de dados, IA e Big Data. Na indústria, representam medições reais de sensores, processos e operações. Quando bem estruturados e analisados, permitem criar soluções que reduzem custos, evitam falhas e aumentam a eficiência.