

Guilherme Tanaka Sebin

**PREDICTIND: SISTEMA INTELIGENTE DE MONITORAMENTO PREDITIVO DE
COMPRESSOR INDUSTRIAL COM IA**

Relatório apresentado à disciplina
Projeto Integrador Big Data na Indústria
III como requisito parcial de avaliação.

Professor: Wellington da Rocha Gouveia

São Carlos

2026

SUMÁRIO

1 INTRODUÇÃO	2
2 PROBLEMA INDUSTRIAL	3
3 OBJETIVOS.....	3
4 ARQUITETURA DA SOLUÇÃO	4
5 TECNOLOGIAS UTILIZADAS.....	4
6 DESCRIÇÃO DOS DADOS.....	4
7 METODOLOGIA	5
8 TREINAMENTO DO MODELO	5
9 RESULTADOS	6
10 MATRIZ DE CONFUSÃO	7
11 ANÁLISE DAS MÉTRICAS	8
12 USO DO MODELO	9
13 INTERPRETAÇÃO	10
14 CONCLUSÃO	10
15 DIFICULDADES.....	10
16 MELHORIAS	11
17 REFERÊNCIAS	11
18 ANEXOS.....	11

1 INTRODUÇÃO

O projeto **PredictInd** propõe a criação de um ecossistema inteligente de análise de dados para o chão de fábrica utilizando Inteligência Artificial (IA) e conceitos estruturais de Big Data. A **manutenção preditiva** é um método avançado de acompanhamento contínuo dos equipamentos, que utiliza dados reais de operação (sensores) para prever o momento exato em que uma peça ou máquina precisará de manutenção, antes mesmo que a falha ocorra.

Para a indústria moderna (Indústria 4.0), essa prática é de extrema importância, pois substitui tanto o modelo reativo (consertar o que já quebrou, paralisando a produção) quanto o preventivo tradicional (trocar peças por calendário, desperdiçando vida útil). O projeto resolve o problema crônico do tempo de inatividade não planejado (*downtime*) e dos altos custos de manutenção emergencial.

2 PROBLEMA INDUSTRIAL

O problema central abordado é o desgaste e a eventual quebra de um **compressor industrial de ar comprimido**, um equipamento vital para alimentar sistemas pneumáticos e linhas de montagem. Os impactos de uma falha imprevista nesse tipo de maquinário são drásticos:

- **Paralisação geral:** A linha de produção para imediatamente.
- **Prejuízos financeiros:** Atraso em entregas, perda de insumos e custo elevado de peças emergenciais.
- **Riscos laborais:** Acidentes envolvendo componentes sob altíssima pressão.

Neste cenário, a manutenção preditiva é fundamental porque elimina o fator surpresa. Monitorar padrões térmicos e de vibração permite que as equipes atuem no equipamento durante janelas programadas, garantindo estabilidade e segurança.

3 OBJETIVOS

- **Objetivo Geral:** Desenvolver e implementar um sistema de monitoramento preditivo capaz de analisar os dados dos sensores de um compressor industrial e, utilizando Aprendizado de Máquina (Redes Neurais), classificar seu status operacional com alta precisão.
- **Objetivos Específicos:**
 1. Gerar conjuntos de dados sintéticos realistas simulando falhas e normalidade.

2. Desenvolver um pipeline de pré-processamento e normalização (`StandardScaler`).
3. Treinar e aferir um modelo multicamadas (`MLPClassifier`).
4. Realizar testes cegos para diagnosticar máquinas em tempo real e fornecer alertas de tomada de decisão.

4 ARQUITETURA DA SOLUÇÃO

A arquitetura do sistema PredictInd atua em formato de pipeline contínuo e divide-se em quatro camadas de dados:

1. **Camada de Coleta/Geração:** Os sinais físicos dos sensores são capturados (em nosso caso, simulados via script) gerando uma matriz tabular de leitura.
2. **Camada de Pré-processamento:** Limpeza e padronização escalar para evitar que unidades grandes (como RPM) ofusquem unidades menores (como Vibração).
3. **Camada de Modelagem (IA):** Uma rede neural processa os dados normalizados através de suas camadas ocultas para extrair correlações invisíveis a olho nu.
4. **Camada de Aplicação:** Os resultados são convertidos em alertas legíveis (Normal, Atenção, Falha) e persistidos em arquivos `.csv` para consumo em dashboards corporativos.

5 TECNOLOGIAS UTILIZADAS

Todo o ecossistema foi construído utilizando a linguagem **Python** e suas bibliotecas focadas em Ciência de Dados:

- **Pandas:** Estruturação, leitura e manipulação das bases de dados através de *DataFrames*.
- **NumPy:** Utilizado para processamento matricial eficiente e aplicação de lógica estocástica para a geração do dataset simulado.
- **Scikit-learn:** Principal núcleo de *Machine Learning* do projeto. Forneceu a separação de dados (`train_test_split`), padronização (`StandardScaler`), e o algoritmo central (`MLPClassifier`), além de todas as métricas de validação.
- **Matplotlib & Seaborn:** Utilizadas para a visualização e estruturação gráfica das métricas analíticas.
- **Joblib:** Ferramenta que possibilitou salvar (serializar) o modelo matemático já treinado no disco.

6 DESCRIÇÃO DOS DADOS

O *dataset* reflete variáveis contínuas cruciais, criadas virtualmente e distribuídas uniformemente:

- **Sensores Base:** Temperatura (°C), Vibração (mm/s), Corrente (A), Tensão (V), Rotação (RPM), Pressão (bar), Ruído (dB), Horas de Operação, Carga de Trabalho (%).
- **Variável Alvo (Classes):**
 - **0 (Normal):** Status ideal da máquina. Nenhuma ação exigida.
 - **1 (Atenção):** Desgaste incipiente detectado; planejamento de manutenção preventiva indicado.
 - **2 (Risco de Falha):** Níveis alarmantes. Intervenção imediata mandatória.



7 METODOLOGIA

A metodologia do sistema foi orquestrada pela execução sequencial de módulos `.py`:

1. **gerar_dados.py:** Simulou matematicamente 300 amostras equilibradas para treinamento e 30 para inferência (uso). Gera *datasets* com nomes `dados_treinamento.csv` e `dados_uso.csv` para serem utilizados pelo modelo.
2. **treinar_modelo.py:** Recebeu os dados brutos, realizou a divisão (80% treino / 20% teste), normalizou o espaço amostral e submeteu os números ao modelo, salvando ao final o arquivo `.pkl`. Também faz plot dos gráficos que serão apresentados a seguir para melhor visualização do modelo e como ele atua.
3. **testar_modelo.py:** Aplicou métricas de auditoria (Acurácia, Precision, Recall) na parcela de teste (60 registros ocultos durante o aprendizado).
4. **usar_modelo.py:** O sistema foi desafiado a processar e diagnosticar novos dados simulados emitindo recomendações baseadas no nível probabilístico.

8 TREINAMENTO DO MODELO

O modelo escolhido foi o **Perceptron de Múltiplas Camadas (MLPClassifier)** parametrizado com duas camadas ocultas principais (64 e 32 neurônios), ativadas pela função *ReLU*. O otimizador de descida de gradiente *Adam* foi o encarregado pelo ajuste dos pesos sinápticos. Conforme plotado abaixo na Curva de *Loss*, o modelo precisou de apenas **135 épocas** para reduzir seu erro (loss final: 0.0044) e atingir o equilíbrio de aprendizado perfeito.



9 RESULTADOS

Ao avaliarmos o modelo treinado com os 20% de dados ocultos (60 amostras), a rede neural não encontrou dificuldade em abstrair a lógica subjacente às classes. A **Acurácia Global (Accuracy) atingiu incríveis 100% (1.00)**. A precisão absoluta reflete que as premissas matemáticas implantadas nos sensores geraram fronteiras de predição cristalinas para a inteligência artificial.

```

temperatura,vibricao,corrente,tensao,rotacao,pressao,ruído,horas_operacao,carga_trabalho,predicao_codigo,status_previsto,confianca_pct
97.2,6.51,29.13,193.76,2210.55,4.07,107.3,2464.94,94.96,2,Δ RISCO DE FALHA IMINENTE Δ,99.9%
109.06,8.85,29.96,194.64,2330.36,4.02,104.15,2385.99,91.45,2,Δ RISCO DE FALHA IMINENTE Δ,99.9%
81.23,3.77,23.58,207.76,2710.25,5.35,81.6,1266.36,74.3,1,Atenção: manutenção preventiva recomendada,98.6%
79.63,4.35,22.49,210.48,2726.66,5.21,80.96,1744.46,77.99,1,Atenção: manutenção preventiva recomendada,98.9%
111.22,6.63,31.86,200.25,2452.22,2.51,105.39,3047.32,90.39,2,Δ RISCO DE FALHA IMINENTE Δ,100.0%
108.43,8.46,27.72,197.17,2398.29,3.1,106.59,3580.89,95.37,2,Δ RISCO DE FALHA IMINENTE Δ,100.0%
83.39,4.77,23.14,207.82,2689.92,5.52,77.51,1610.11,83.77,1,Atenção: manutenção preventiva recomendada,99.4%
86.71,4.79,22.09,211.33,2679.48,5.37,82.28,1876.58,83.41,1,Atenção: manutenção preventiva recomendada,99.2%
64.02,0.65,18.19,222.27,2950.47,6.92,66.17,322.62,43.71,0,Operação Normal,100.0%
53.64,0.91,18.66,220.24,2853.54,7.0,69.84,118.62,49.14,0,Operação Normal,99.9%
101.78,5.36,27.9,200.19,2210.0,3.22,97.97,2151.07,98.68,2,Δ RISCO DE FALHA IMINENTE Δ,99.8%
83.66,3.35,22.86,206.2,2696.94,5.56,77.83,1310.0,76.77,1,Atenção: manutenção preventiva recomendada,99.0%
65.85,1.27,14.76,223.12,2937.39,6.21,62.91,57.06,58.4,0,Operação Normal,99.9%
75.04,4.47,23.82,212.61,2773.62,5.47,83.84,1731.58,73.94,1,Atenção: manutenção preventiva recomendada,98.9%
72.19,3.21,22.71,212.48,2656.59,5.54,78.55,1339.5,82.18,1,Atenção: manutenção preventiva recomendada,99.6%
55.55,2.84,12.0,216.14,2948.63,7.55,62.56,289.02,42.46,0,Operação Normal,100.0%
87.14,4.63,22.84,211.46,2696.21,5.45,78.43,1582.02,74.23,1,Atenção: manutenção preventiva recomendada,98.7%
86.69,3.36,23.01,207.55,2626.23,5.13,78.23,1830.09,75.39,1,Atenção: manutenção preventiva recomendada,98.1%
108.43,7.19,33.45,199.34,2479.72,4.43,92.76,3543.08,89.34,2,Δ RISCO DE FALHA IMINENTE Δ,99.8%
99.94,6.64,33.85,201.28,2469.43,4.06,98.8,3802.12,92.96,2,Δ RISCO DE FALHA IMINENTE Δ,99.9%
99.63,8.88,28.45,191.85,2235.53,4.64,97.65,2807.41,96.73,2,Δ RISCO DE FALHA IMINENTE Δ,99.9%
62.31,1.93,12.18,222.49,2924.47,6.8,69.76,283.91,50.97,0,Operação Normal,100.0%
67.77,1.85,18.7,216.6,2875.82,6.51,63.55,176.72,58.18,0,Operação Normal,99.6%
87.21,4.13,22.87,210.06,2702.67,5.63,78.98,1367.75,82.73,1,Atenção: manutenção preventiva recomendada,99.6%
108.31,5.92,32.46,198.01,2562.32,2.21,92.57,3162.87,90.56,2,Δ RISCO DE FALHA IMINENTE Δ,99.9%
63.93,2.86,17.35,222.83,2853.56,7.83,63.56,906.29,67.87,0,Operação Normal,98.7%
62.98,1.66,15.37,219.46,2817.9,6.4,66.79,238.27,43.3,0,Operação Normal,99.9%
112.74,8.67,33.89,200.05,2355.48,3.69,100.88,2195.14,93.53,2,Δ RISCO DE FALHA IMINENTE Δ,99.9%
47.93,1.17,14.87,221.98,2895.29,6.2,73.45,898.45,62.41,0,Operação Normal,99.8%
49.63,2.38,15.14,218.78,2876.91,6.1,64.9,631.81,67.33,0,Operação Normal,99.8%

```

Resultado_uso_ia.csv

```

=====
PredictInd - Resultado do Teste do Modelo
Monitoramento Preditivo de Compressor Industrial
=====

MÉTRICAS DE DESEMPENHO:
Acurácia : 100.00%
Precisão : 100.00%
Recall : 100.00%
F1-Score : 100.00%

RELATÓRIO DE CLASSIFICAÇÃO POR CLASSE:

```

	precision	recall	f1-score	support
Normal	1.00	1.00	1.00	20
Atenção	1.00	1.00	1.00	20
Risco de Falha	1.00	1.00	1.00	20

```


```

	accuracy	macro avg	weighted avg
	1.00	1.00	1.00
	1.00	1.00	1.00
	1.00	1.00	1.00

```

MATRIZ DE CONFUSÃO:
(Linhas = Real | Colunas = Previsto)
Classes: [Normal, Atenção, Risco de Falha]

[[20  0  0]
 [ 0 20  0]
 [ 0  0 20]]

INTERPRETAÇÃO DA MATRIZ DE CONFUSÃO:
Classe 'Normal': 20/20 corretos (100.0%)
Classe 'Atenção': 20/20 corretos (100.0%)
Classe 'Risco de Falha': 20/20 corretos (100.0%)



ARQUIVOS DE GRÁFICOS GERADOS:
→ grafico_matriz_confusao_teste.png
→ grafico_metricas_por_classe.png

```

resultados_teste.txt


10 MATRIZ DE CONFUSÃO

A Matriz de Confusão para a base de testes comprova ausência total de "Falsos Positivos" e "Falsos Negativos". Os 20 registros "Normais" foram preditos perfeitamente como "Normais", assim como todos os 20 de "Atenção" e os 20 de "Risco de Falha". Não houve vazamento algorítmico entre as previsões, demonstrando confiabilidade impecável.



11 ANÁLISE DAS MÉTRICAS


- **Precisão (Precision) - 100%:** O algoritmo jamais emitiu um alarme falso sobre um equipamento que não precisava de intervenção.
- **Recall (Sensibilidade) - 100%:** Nenhum compressor que de fato estivesse em risco de quebra passou despercebido.
- **F1-Score - 100%:** O balanço harmônico validou que o modelo não privilegiou nenhuma classe em detrimento da outra.



12 USO DO MODELO

No teste de campo virtual (`usar_modelo.py`), submetemos 30 novas amostras independentes ao sistema. O software extraiu não apenas a classificação rígida, mas uma **taxa de confiança de inferência** (majoritariamente mantida acima de 98.6%). O log das predições devolveu alertas semânticos imediatos, instruindo as equipes de mecânicos exatamente sobre o que observar.

A correlação analítica entre variáveis chaves, como Temperatura x Vibração, após serem classificadas pela máquina, mostra os agrupamentos (*clusters*) evidentes entre os estágios do compressor:



Grafico_temp_vibracao_classificado.png

O perfil de previsões resultantes da bateria final de uso ficou perfeitamente distribuído, acionando manutenção imediata para 1/3 do parque fabril.

13 INTERPRETAÇÃO

Interpreta-se que o modelo MLP se adaptou perfeitamente aos padrões de limite dos componentes do compressor. Sensores como "Vibração" e "Temperatura" funcionam de forma colinear (quando o motor sobreaquece, ele vibra mais em virtude do atrito). A rede neural conseguiu mapear essas correlações multidimensionais e criar equações robustas o suficiente para detectar qualquer assinatura de anomalia.

14 CONCLUSÃO

A tese levantada no início do projeto foi integralmente confirmada. Sistemas baseados em Data Science e Machine Learning, atuando no papel de previsão industrial, são altamente eficazes para mitigar o colapso estrutural de máquinas. Ao prever o estado operacional do compressor com 100% de margem de acerto sobre a simulação paramétrica, comprova-se que o Big Data é a chave para o corte de custos e aumento exponencial do OEE (Eficiência Geral dos Equipamentos) na indústria.

15 DIFICULDADES

Um desafio conceitual importante residiu na aplicação correta da técnica de escalonamento. Garantir que o `StandardScaler` aplicasse a extração estatística (`fit_transform`)

unicamente nos dados de treino, e projetasse essas proporções via `transform` isolado para o banco de dados de teste e novos dados, requereu um planejamento robusto para não contaminar a inteligência com o temido fenômeno de Vazamento de Dados (*Data Leakage*).

16 MELHORIAS

- Implementar sobreposição (*overlap*) nos dados de simulação em versões futuras, tornando o balizamento estocástico mais complexo.
- Conectar o script a uma plataforma real de IoT (*Internet of Things*) baseada em nuvem, garantindo a ingestão e alerta de dados em rede Wi-Fi / MQTT no *Edge Computing*.

17 REFERÊNCIAS

- GOUVEIA, Wellington da Rocha. Material da disciplina: Projeto Integrador Big Data na Indústria III.
- PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 2011.
- MCKINNEY, W. pandas: a foundational Python library for data analysis and statistics. Python for High Performance and Scientific Computing, 2011.
- HARRIS, C. R. et al. Array programming with NumPy. Nature, 2020.

18 ANEXOS

Os *scripts* bases (`gerar_dados.py`, `treinar_modelo.py`, `testar_modelo.py` e `usar_modelo.py`) e os artefatos seriais matemáticos (`.pkl`) e tabulares (`.csv`) elaborados para viabilizar as extrações deste relatório, encontram-se listados no repositório final de projeto.

É possível visualizar e realizar o download do modelo e dos códigos fonte para criação de dados pelo link:

https://github.com/GuilhermeSebin/FATEC_semestre3/tree/main/Projeto_integrador_II/projeto_final