

CURSO SUPERIOR DE TECNOLOGIA EM BIG DATA PARA A INDÚSTRIA

Guilherme Tanaka Sebin

**PREDICTIND: SISTEMA INTELIGENTE DE MONITORAMENTO PREDITIVO DE
COMPRESSOR INDUSTRIAL COM IA**

Relatório apresentado à disciplina
Projeto Integrador Big Data na Indústria
III como requisito parcial de avaliação.

Professor: Wellington da Rocha Gouveia

São Carlos

2026

Sumário

1 INTRODUÇÃO	2
2 PROBLEMA INDUSTRIAL	3
3 OBJETIVOS.....	3
4 ARQUITETURA DA SOLUÇÃO	4
5 TECNOLOGIAS UTILIZADAS	4
6 DESCRIÇÃO DOS DADOS	5
7 METODOLOGIA	5
8 TREINAMENTO DO MODELO	5
9 RESULTADOS.....	6
10 MATRIZ DE CONFUSÃO.....	6
11 ANÁLISE DAS MÉTRICAS.....	6
12 USO DO MODELO	7
13 INTERPRETAÇÃO	7
14 CONCLUSÃO	7
15 DIFICULDADES.....	7
16 MELHORIAS.....	8
17 REFERÊNCIAS	8
18 ANEXOS.....	8

1 INTRODUÇÃO

O projeto **PredictInd** propõe a criação de um ecossistema inteligente de análise de dados para o chão de fábrica utilizando Inteligência Artificial (IA) e conceitos estruturais de Big Data. A **manutenção preditiva** é um método avançado de acompanhamento contínuo dos equipamentos, que utiliza dados reais de operação (sensores) para prever o momento exato em que uma peça ou máquina precisará de manutenção, antes mesmo que a falha ocorra.

Para a indústria moderna (Indústria 4.0), essa prática é de extrema importância, pois substitui tanto o modelo reativo (consertar o que já quebrou, paralisando a produção) quanto o preventivo tradicional (trocar peças por calendário, desperdiçando vida útil). O projeto resolve o problema crônico do tempo de inatividade não planejado (downtime) e dos altos custos de manutenção emergencial.

2 PROBLEMA INDUSTRIAL

O problema central abordado é o desgaste e a eventual quebra de um **compressor industrial de ar comprimido**, um equipamento vital para alimentar sistemas pneumáticos e linhas de montagem. Os impactos de uma falha imprevista nesse tipo de maquinário são drásticos:

- **Paralisação geral:** A linha de produção para imediatamente.
- **Prejuízos financeiros:** Atraso em entregas, perda de insumos e custo elevado de peças emergenciais.
- **Riscos laborais:** Acidentes envolvendo componentes sob altíssima pressão.

Neste cenário, a manutenção preditiva é fundamental porque elimina o fator surpresa. Monitorar padrões térmicos e de vibração permite que as equipes atuem no equipamento durante janelas programadas, garantindo estabilidade e segurança.

3 OBJETIVOS

Objetivo Geral: Desenvolver e implementar um sistema de monitoramento preditivo capaz de analisar os dados dos sensores de um compressor industrial e, utilizando Aprendizado de Máquina (Redes Neurais), classificar seu status operacional com alta precisão, considerando cenários de dados desbalanceados e sobreposição (overlap).

Objetivos Específicos:

1. Gerar conjuntos de dados sintéticos realistas simulando falhas e normalidade, refletindo uma distribuição desigual típica do chão de fábrica.
2. Desenvolver um pipeline de pré-processamento e normalização (StandardScaler) evitando vazamento de dados.

3. Treinar e aferir um modelo multicamadas (MLPClassifier) com hiperparâmetros ajustados para alta complexidade.
4. Realizar testes cegos para diagnosticar máquinas em tempo real e fornecer alertas de tomada de decisão.

4 ARQUITETURA DA SOLUÇÃO

A arquitetura do sistema PredictInd atua em formato de pipeline contínuo e divide-se em quatro camadas de dados:

1. **Camada de Coleta/Geração:** Os sinais físicos dos sensores são capturados (em nosso caso, simulados via script) gerando uma matriz tabular de leitura.
2. **Camada de Pré-processamento:** Limpeza e padronização escalar para evitar que unidades grandes (como RPM) ofusquem unidades menores (como Vibração).
3. **Camada de Modelagem (IA):** Uma rede neural processa os dados normalizados através de suas camadas ocultas para extrair correlações invisíveis a olho nu.
4. **Camada de Aplicação:** Os resultados são convertidos em alertas legíveis (Normal, Atenção, Falha) e persistidos em arquivos .csv para consumo em dashboards corporativos.

5 TECNOLOGIAS UTILIZADAS

Todo o ecossistema foi construído utilizando a linguagem Python e suas bibliotecas focadas em Ciência de Dados:

- **Pandas:** Estruturação, leitura e manipulação das bases de dados através de DataFrames.
- **NumPy:** Utilizado para processamento matricial eficiente e aplicação de lógica estocástica para a geração do dataset simulado.
- **Scikit-learn:** Principal núcleo de Machine Learning do projeto. Forneceu a separação de dados, padronização, e o algoritmo central, além das métricas de validação.
- **Matplotlib & Seaborn:** Utilizadas para a visualização e estruturação gráfica das métricas analíticas.
- **Joblib:** Ferramenta que possibilitou salvar (serializar) o modelo matemático já treinado no disco.

6 DESCRIÇÃO DOS DADOS

O dataset reflete variáveis contínuas cruciais, criadas virtualmente. Em sua nova iteração, os dados apresentam uma distribuição desbalanceada para refletir fielmente o cenário industrial,

onde falhas são eventos raros em comparação com a operação normal (80% Normal, 15% Atenção, 5% Risco).

- **Sensores Base:** Temperatura (°C), Vibração (mm/s), Corrente (A), Tensão (V), Rotação (RPM), Pressão (bar), Ruído (dB), Horas de Operação, Carga de Trabalho (%).

- **Variável Alvo (Classes):**

- **0 (Normal):** Status ideal da máquina. Nenhuma ação exigida.

- **1 (Atenção):** Desgaste incipiente detectado; planejamento de manutenção preventiva indicado.

- **2 (Risco de Falha):** Níveis alarmantes. Intervenção imediata mandatária.

7 METODOLOGIA

A metodologia do sistema foi orquestrada pela execução sequencial de módulos .py:

1. **gerar_dados.py:** Simulou matematicamente 1000 amostras equilibradas para treinamento e 100 amostras adicionais para inferência (uso) no cenário real.



2. **treinar_modelo.py:** Recebeu os dados brutos, realizou a divisão (80% treino resultando em 800 amostras / 20% teste resultando em 200 amostras), normalizou o espaço amostral de forma isolada e submeteu os números ao modelo.

3. **testar_modelo.py:** Aplicou métricas de auditoria (Acurácia, Precision, Recall) na parcela de teste de 200 registros.

4. **usar_modelo.py:** O sistema processou 100 novos dados simulados emitindo recomendações baseadas no nível probabilístico.

8 TREINAMENTO DO MODELO

O modelo escolhido foi o **Perceptron de Múltiplas Camadas (MLPClassifier)** parametrizado com duas camadas ocultas principais (64 e 32 neurônios), ativadas pela função ReLU. O otimizador de descida de gradiente Adam foi o encarregado pelo ajuste dos pesos sinápticos. Para contornar a nova complexidade do dataset, que agora inclui sobreposição de dados (overlap) e classes severamente desbalanceadas, o parâmetro `max_iter` foi estendido para 800 épocas. Isso garantiu que o algoritmo de descida de gradiente tivesse tempo e ciclos suficientes para encontrar o mínimo global do erro (Loss) e abstrair corretamente as fronteiras de decisão.



9 RESULTADOS

Ao avaliarmos o modelo treinado com os 20% de dados de teste (200 amostras), observou-se a eficácia absoluta da configuração. O conjunto de teste apresentou a exata proporção da vida

real embutida no gerador: 160 ocorrências normais, 31 em estado de atenção e apenas 9 em risco de falha. Mesmo com esse forte desbalanceamento e a presença de overlap estocástico, a Acurácia Global (Accuracy) manteve-se em perfeitos 100% (1.00). A rede neural não apresentou nenhum viés para a classe majoritária, aprendendo perfeitamente as assinaturas de falha minoritárias.

```
temperatura,vibricao,corrente,tensao,rotacao,pressao,ruido,horas_operacao,carga_trabalho,predicao_codigo,status_previsto,confianca
64.74,2.87,12.32,213.93,2878.15,6.33,75.49,568.51,67.99,0,Operação Normal,99.8%
49.42,2.27,17.32,212.31,2948.43,7.46,64.27,346.4,72.83,0,Operação Normal,100.0%
52.78,3.21,16.04,216.97,2999.38,6.73,63.21,615.68,68.49,0,Operação Normal,100.0%
42.34,3.33,21.84,211.33,2822.82,6.43,73.98,715.11,62.55,0,Operação Normal,99.4%
49.33,3.4,11.92,221.81,2996.04,5.55,72.58,303.49,41.42,0,Operação Normal,100.0%
60.32,2.82,13.99,222.47,2818.64,6.87,63.85,570.63,51.14,0,Operação Normal,100.0%
49.62,2.65,17.14,214.87,2756.34,7.38,63.87,1001.37,54.71,0,Operação Normal,100.0%
69.85,3.42,13.2,220.74,2848.56,7.19,68.57,1192.53,65.51,0,Operação Normal,99.8%
85.76,3.75,20.13,213.33,2606.73,6.36,84.04,1915.18,73.63,1,Atenção,98.6%
73.93,0.62,19.04,217.88,2842.16,5.66,71.2,702.26,49.83,0,Operação Normal,99.9%
116.51,5.71,35.83,199.11,2388.67,4.61,106.01,2504.25,91.45,2,△ RISCO DE FALHA △,98.8%
74.88,3.41,25.44,203.43,2681.66,5.4,82.11,2052.59,85.62,1,Atenção,99.4%
67.85,1.75,12.75,213.48,2975.35,7.58,69.96,739.33,56.6,0,Operação Normal,100.0%
57.71,3.25,11.51,216.28,2836.14,6.75,68.24,622.67,44.9,0,Operação Normal,100.0%
56.52,3.22,14.36,214.31,2875.18,6.64,66.2,832.49,66.58,0,Operação Normal,99.9%
72.8,2.38,13.86,213.7,2752.25,6.09,62.48,734.6,45.83,0,Operação Normal,99.9%
70.9,2.93,21.61,217.17,2931.85,6.43,63.32,531.69,45.8,0,Operação Normal,100.0%
60.02,3.18,15.7,224.18,2803.61,5.69,76.05,1017.22,74.74,0,Operação Normal,99.4%
89.52,5.1,22.27,212.58,2575.89,6.18,76.14,1099.51,81.55,1,Atenção,99.9%
74.0,0.85,21.5,211.37,2807.76,5.62,72.69,1020.36,55.19,0,Operação Normal,97.7%
63.39,2.72,15.38,224.06,2934.16,6.64,70.25,831.14,60.73,0,Operação Normal,100.0%
44.17,2.45,16.81,218.3,2757.96,6.67,76.64,477.11,61.87,0,Operação Normal,99.9%
55.11,1.86,16.15,220.7,2818.38,5.8,70.01,392.37,55.49,0,Operação Normal,100.0%
42.63,3.19,19.63,212.09,2944.19,7.06,67.36,304.83,70.09,0,Operação Normal,100.0%
48.48,1.74,12.79,217.37,2968.12,7.28,70.44,106.8,64.29,0,Operação Normal,100.0%
60.2,3.12,20.36,215.57,2802.22,7.44,67.8,230.45,71.65,0,Operação Normal,99.9%
62.64,1.98,17.44,218.16,2934.95,7.26,69.62,814.68,70.57,0,Operação Normal,100.0%
69.64,2.3,18.18,224.9,2808.08,7.06,68.29,47.34,40.51,0,Operação Normal,100.0%
71.86,1.41,15.4,218.16,2775.06,7.83,66.74,96.94,53.56,0,Operação Normal,100.0%
61.52,3.21,21.55,219.8,2959.54,6.81,63.75,629.63,59.43,0,Operação Normal,100.0%
57.96,1.23,12.21,210.97,2940.66,6.57,71.28,873.11,63.78,0,Operação Normal,100.0%
43.74,2.96,15.23,211.09,2946.55,6.44,61.81,760.53,70.8,0,Operação Normal,100.0%
63.42,3.33,19.88,210.63,2867.77,6.49,65.58,541.6,53.45,0,Operação Normal,99.7%
74.37,0.79,17.07,219.4,2884.52,7.16,62.09,666.02,50.05,0,Operação Normal,100.0%
71.12,3.31,10.64,217.51,2843.74,7.06,74.28,336.71,59.49,0,Operação Normal,100.0%
54.13,1.12,17.78,223.07,2937.08,7.67,69.66,902.25,44.9,0,Operação Normal,100.0%
65.29,0.76,12.64,210.13,2929.03,6.36,74.16,406.72,68.68,0,Operação Normal,100.0%
60.61,2.87,17.87,219.13,2852.95,6.68,67.46,1010.6,48.05,0,Operação Normal,99.9%
74.02,2.35,21.78,215.07,2925.76,6.06,64.7,614.28,51.19,0,Operação Normal,99.9%
48.59,2.61,11.19,223.63,2803.76,6.01,63.27,16.78,67.01,0,Operação Normal,100.0%
57.05,1.57,13.02,220.42,2942.37,6.11,60.89,1018.5,40.35,0,Operação Normal,100.0%
56.47,1.66,14.51,219.6,2873.7,7.62,75.74,204.67,44.77,0,Operação Normal,100.0%
57.29,0.67,21.46,211.93,2924.37,6.77,60.46,1109.7,69.81,0,Operação Normal,100.0%
56.73,1.17,18.47,212.86,2888.21,6.13,77.2,34.36,46.99,0,Operação Normal,100.0%
69.21,1.58,17.35,212.29,2766.54,6.04,62.3,374.89,58.0,0,Operação Normal,99.9%
40.2,1.4,18.99,221.91,2800.62,7.9,69.04,1100.37,64.74,0,Operação Normal,100.0%
51.03,2.13,11.09,220.18,2931.27,7.91,64.69,22.15,59.1,0,Operação Normal,100.0%
```

Resultado_uso_ia.csv



Acurácia: 100.00%						
						</

resultados_teste.txt

10 MATRIZ DE CONFUSÃO

A Matriz de Confusão para a base de testes comprova ausência total de "Falsos Positivos" e "Falsos Negativos". Não houve vazamento algorítmico entre as previsões, demonstrando confiabilidade impecável.


Classe Real/Prevista	Normal	Atenção	Risco de Falha
Normal	160	0	0
Atenção	0	31	0
Risco de Falha	0	0	9



11 ANÁLISE DAS MÉTRICAS


- Precisão (Precision) - 100%: O algoritmo jamais emitiu um alarme falso sobre um equipamento que não precisava de intervenção (1.00 para todas as classes).

- Recall (Sensibilidade) - 100%: Nenhum compressor que de fato estivesse em risco de quebra passou despercebido (1.00 para todas as classes).
- F1-Score - 100%: O balanço harmônico validou que o modelo não privilegiou a classe majoritária ("Normal" com 160 ocorrências) em detrimento da classe minoritária ("Risco de Falha" com 9 ocorrências).



12 USO DO MODELO

No teste de campo virtual (`usar_modelo.py`), submetemos 100 novas amostras independentes ao sistema. O software extraiu não apenas a classificação rígida, mas uma taxa de confiança de inferência para o novo cenário. O log das predições devolveu alertas semânticos imediatos, instruindo as equipes de mecânicos exatamente sobre o que observar. A correlação analítica entre variáveis chaves, como Temperatura x Vibração, após serem classificadas pela máquina, mostra os agrupamentos (clusters) evidentes entre os estágios do compressor na nova simulação.



13 INTERPRETAÇÃO

Interpreta-se que o modelo MLP se adaptou perfeitamente aos padrões de limite dos componentes do compressor, mesmo com sobreposição de dados. Sensores como "Vibração" e "Temperatura" funcionam de forma colinear (quando o motor sobreaquece, ele vibra mais em virtude do atrito). A rede neural conseguiu mapear essas correlações multidimensionais e criar equações robustas o suficiente para detectar qualquer assinatura de anomalia.

14 CONCLUSÃO

A tese levantada no início do projeto foi integralmente confirmada. Sistemas baseados em Data Science e Machine Learning, atuando no papel de predição industrial, são altamente eficazes para mitigar o colapso estrutural de máquinas. Ao prever o estado operacional do compressor com 100% de margem de acerto sobre a simulação paramétrica - adaptada perfeitamente à distribuição 80/15/5 da realidade fabril - comprova-se que o Big Data é a chave para o corte de custos e aumento exponencial do OEE (Eficiência Geral dos Equipamentos) na indústria.

15 DIFICULDADES

Um desafio conceitual importante residiu na aplicação correta da técnica de escalonamento diante de dados enviesados. Garantir que o Standard Scaler aplicasse a extração estatística (fit_transform) unicamente nos dados de treino, e projetasse essas proporções via transform isolado para o banco de dados de teste e novos dados, requereu um planejamento robusto para não contaminar a inteligência com o temido fenômeno de Vazamento de Dados (Data Leakage).

16 MELHORIAS

- Implementar parâmetros de busca em grade (GridSearchCV) para aferir automaticamente a necessidade exata de épocas e arquitetura de rede em produções futuras.
- Conectar o script a uma plataforma real de IoT (Internet of Things) baseada em nuvem, garantindo a ingestão e alerta de dados em rede Wi-Fi/MQTT no Edge Computing.

17 REFERÊNCIAS

- GOUVEIA, Wellington da Rocha. Material da disciplina: Projeto Integrador Big Data na Indústria III.
- PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 2011.
- MCKINNEY, W. pandas: a foundational Python library for data analysis and statistics. Python for High Performance and Scientific Computing, 2011.
- HARRIS, C. R. et al. Array programming with NumPy. Nature, 2020.

18 ANEXOS

Os scripts bases (gerar_dados.py, treinar_modelo.py, testar_modelo.py e usar_modelo.py) e os artefatos seriais matemáticos (.pkl) e tabulares (.csv) elaborados para viabilizar as extrações deste relatório, encontram-se listados no repositório final de projeto.

É possível visualizar e realizar o download do modelo e dos códigos fonte para criação de dados pelo link: