

# 1. Kaggle Datasets (Google) – Repositório completo para ML

O Kaggle é uma das maiores plataformas de datasets para Machine Learning, amplamente utilizada por iniciantes e profissionais.

Ele oferece milhares de conjuntos de dados de diferentes áreas (saúde, educação, vendas, imagens etc.) e suporte a notebooks para treinar modelos.

✦ A busca confirma que Kaggle é um dos principais repositórios de datasets abertos para ML, com filtros, popularidade e categorização [\[kaggle.com\]](https://www.kaggle.com)

🔗 <https://www.kaggle.com/datasets>

---

## 2. Google Dataset Search – Buscador global de datasets

Permite encontrar bases de dados publicadas por universidades, organizações, governos e pesquisadores.

A busca indica que o Google Dataset Search agrega datasets de organizações como OMS, Statista e Harvard, acessíveis através da Google Cloud. [\[imerit.net\]](https://datasetsearch.google.com)

🔗 <https://datasetsearch.google.com>

---

## 3. OpenML – Plataforma mundial para ML

Permite baixar datasets já padronizados para uso direto em bibliotecas como Scikit-learn.

Segundo a pesquisa, o OpenML funciona como um grande laboratório mundial para compartilhar datasets, algoritmos e experimentos. [\[openml.org\]](https://www.openml.org/)

🔗 <https://www.openml.org/>

---

## 4. Registry of Open Data on AWS

Repositório gratuito da Amazon Web Services com datasets acessíveis diretamente na nuvem.

A pesquisa cita que usuários podem baixar os dados gratuitamente e usar ferramentas de análise na AWS (cobradas separadamente). [\[imerit.net\]](https://www.imerit.net/)

🔗 <https://registry.opendata.aws/>

---

## 5. UCI Machine Learning Repository (clássico)

Um dos repositórios de datasets mais tradicionais da área, muito usado em cursos técnicos e universitários.

Foi destacado como uma fonte histórica e confiável de datasets estruturados para ML. [\[capmonster.cloud\]](https://archive.ics.uci.edu/ml/index.php)

🔗 <https://archive.ics.uci.edu/ml/index.php>

---

## 6. Data.gov – Dados abertos do governo dos EUA

Grande portal de dados públicos, incluindo:

- economia
- meio ambiente
- educação
- saúde
- segurança pública

Diversos datasets são ideais para ML.

🔗 <https://www.data.gov/>

---

## 7. Data.World – Plataforma de datasets colaborativos

Permite acessar e publicar datasets, com foco em comunidades de dados.

A busca confirma que Data.World é uma plataforma colaborativa com milhões de entradas de dados organizados em catálogo. [\[imerit.net\]](https://imerit.net)

 <https://data.world/>

---

## 8. AWS DynamoDB / MongoDB / Redis / PostgreSQL como bancos para armazenar seus dados

Se o objetivo é **criar seu próprio banco de dados** para alimentar modelos, os melhores bancos recomendados para Machine Learning segundo estudo recente são:

- **MongoDB**
- **Redis**
- **Couchbase**
- **HBase**
- **PostgreSQL**
- **MySQL**

Estes bancos aparecem na lista dos principais bancos utilizados em ML pela GeeksforGeeks. [\[geeksforgeeks.org\]](https://www.geeksforgeeks.org)

 <https://www.mongodb.com>

 <https://redis.io>

 <https://www.postgresql.org>